



RAPPORT TECHNIQUE DE PROJET

Analyse de Sentiments Orientée Aspect (ABSA)

Conception d'un pipeline NLP et Fine-Tuning
d'un modèle Transformer sous contraintes GPU

Réalisé par :

Mani YASSIR & Hilali SAMI

Encadré par :

Pr. Nouredine MOHTARAM

Résumé

Le traitement automatique des langues (NLP) offre des outils puissants pour l'analyse des retours clients. Toutefois, la classification binaire (positif/négatif) appliquée à des textes entiers montre des limites face à des avis nuancés ou mitigés.

Ce rapport présente la conception d'un pipeline d'Analyse de Sentiment Orientée Aspect (*Aspect-Based Sentiment Analysis - ABSA*). Notre approche combine un nettoyage et une tokenisation par règles linguistiques via **NLTK**, suivis d'un *Fine-Tuning* du modèle **DistilBERT**.

Face à des contraintes matérielles strictes (GPU de 4 Go de VRAM), le système a été optimisé par l'utilisation de la précision mixte (FP16) et d'un contrôle strict de la taille des séquences. Évalué sur un jeu de données Amazon de 141 Mo, notre modèle final atteint une exactitude de **85,60 %** sur des données inédites, prouvant son absence de sur-apprentissage et sa viabilité pour un déploiement métier via Microsoft Power BI.

Outils utilisés : Python, NLTK, Hugging Face Transformers, PyTorch, SQLite, Power BI.

Table des matières

Résumé	2
1 Introduction & Problématique	4
1.1 Contexte Linguistique et Métier	4
1.2 Objectifs du Projet	4
2 Data Engineering et Traitement du Corpus	5
2.1 Description du Dataset	5
2.2 Nettoyage et Normalisation Linguistique	5
2.3 Segmentation par Clause Sémantique	5
2.4 Tokenisation et Stratégie de Padding	6
3 Architecture du Modèle	7
3.1 Le Choix de l'Architecture : De BERT à DistilBERT	7
3.2 Le Mécanisme de Self-Attention	7
3.3 Couche de Classification et Fonction de Perte . . .	7
4 Entraînement et Expérimentations	9
4.1 Hyperparamètres et Configuration d'Apprentissage	9
4.2 Optimisation de la Précision Mixte (FP16)	9
5 Résultats et Déploiement	10
5.1 Protocole de Test : L'Échappement (<i>Hold-out Test</i>)	10
5.2 Analyse des Métriques et Matrice de Confusion . .	10
5.3 Restitution Visuelle et Opérationnelle (Power BI) .	10
5.3.1 Le Tableau de Bord Stratégique (Vue Décisionnelle)	11
5.3.2 L'Outil CRM d'Alertes SAV (Vue Opérationnelle)	11
Conclusion Générale et Perspectives	13

1 Introduction & Problématique

1.1 Contexte Linguistique et Métier

À l'ère du commerce électronique, les entreprises accumulent quotidiennement des milliers d'avis sous forme de textes non structurés. Extraire la polarité de ces commentaires est essentiel pour la gestion de la relation client.

Historiquement, l'analyse de sentiment s'opérait au niveau du document. Cependant, le langage humain est riche en ambiguïtés et en oppositions sémantiques.

C'est ici qu'intervient l'Analyse Orientée Aspect (ABSA). L'objectif n'est plus de juger le document dans son ensemble, mais de lier une entité cible (l'aspect) au sentiment qui la qualifie au sein même d'une proposition.

1.2 Objectifs du Projet

Ce projet vise à résoudre une problématique métier fictive mais réaliste (baisse de fidélité de 15% sur une plateforme e-commerce d'accessoires de téléphonie) en développant un pipeline NLP *End-to-End* :

1. **Ingénierie de la donnée** : Nettoyage et découpage du texte au niveau de la clause linguistique.
2. **Apprentissage Profond** : Fine-Tuning d'un modèle d'attention (Transformer) spécialisé sur le lexique de la téléphonie.
3. **Restitution** : Connexion du modèle à un outil de *Business Intelligence* pour automatiser les alertes du service après-vente.

Dans les chapitres suivants, nous détaillerons l'ingénierie du corpus (Chapitre 2), l'architecture mathématique et logicielle du modèle (Chapitre 3), la phase d'entraînement (Chapitre 4) et enfin la discussion de nos résultats (Chapitre 5).

Exemple d'avis mitigé :

« *The screen is amazing, but the battery dies too fast.* »

L'algorithme classique donne le label "Neutre" car les polarités s'annulent. L'information critique sur la batterie est perdue.

2 Data Engineering et Traitement du Corpus

2.1 Description du Dataset

Pour entraîner notre modèle aux spécificités du jargon technologique, nous avons utilisé un jeu de données public issu des avis clients de la plateforme Amazon, spécifiquement ciblé sur la catégorie *Cell Phones & Accessories*.

Le fichier brut, au format JSON Lines, pèse 141 Mo et contient des métadonnées essentielles telles que la note globale (sur 5 étoiles), le titre de l'avis (`summary`) et le corps du texte (`reviewText`).

2.2 Nettoyage et Normalisation Linguistique

Le pré-traitement pour l'Analyse Orientée Aspect (ABSA) diffère radicalement du NLP classique. Habituellement, les ingénieurs suppriment toute la ponctuation. Dans notre cas, la ponctuation est la clé de voûte permettant de séparer les différents aspects d'une même phrase.

Nous avons développé un pipeline hybride utilisant des expressions régulières (Regex) et la bibliothèque **NLTK** (*Natural Language Toolkit*) :

- **Normalisation** : Passage en minuscules et suppression des caractères HTML ou artefacts de formatage.
- **Filtrage des Stopwords** : Utilisation du corpus `stopwords` de NLTK pour retirer les mots vides de sens, tout en conservant les conjonctions de coordination (*but, and, however*) indispensables à la compréhension des revirements de situation.

2.3 Segmentation par Clause Sémantique

L'innovation linguistique de notre pipeline réside dans le découpage de l'avis original en sous-propositions indépendantes.

À l'aide d'une fonction Python, le texte est "haché" dès qu'il rencontre une ponctuation forte (., , , !) ou une conjonction d'opposition. Chaque segment est ensuite scanné. S'il contient un mot issu de notre ontologie métier (ex : *screen, battery, shipping*), l'aspect correspondant lui est assigné.

Déséquilibre des classes :

Dans les datasets e-commerce, les avis à 5 étoiles (Positifs) sont souvent surreprésentés par rapport aux avis à 1 ou 2 étoiles (Négatifs). Cela nécessite un suivi rigoureux de la métrique F1-Score plutôt que de la simple Accuracy.

2.4 Tokenisation et Stratégie de Padding

Pour que les segments textuels soient ingérés par notre réseau de neurones, ils doivent être vectorisés. Nous avons utilisé le *Tokenizer* natif d'Hugging Face.

Pour répondre à nos contraintes matérielles (GPU de 4 Go), nous avons défini une longueur maximale stricte : `max_length = 128`. Les segments plus courts ont subi un ajout de zéros (*Padding*), tandis que les textes plus longs ont été tronqués, limitant ainsi la complexité spatiale.

3 Architecture du Modèle

3.1 Le Choix de l'Architecture : De BERT à DistilBERT

L'architecture *Bidirectional Encoder Representations from Transformers* (BERT) a redéfini l'état de l'art en NLP. Cependant, avec ses 110 millions de paramètres, le *Fine-Tuning* de BERT requiert des ressources de calcul massives, incompatibles avec notre infrastructure locale.

Nous avons opté pour **DistilBERT**. Grâce au processus de distillation de connaissances, ce modèle conserve 97 % des performances de compréhension du langage de BERT, tout en réduisant le nombre de paramètres de 40 % et en augmentant la vitesse d'inférence de 60 %.

Distillation de Connaissances :

C'est un processus de compression où un "modèle élève" (plus petit) est entraîné pour reproduire le comportement d'un "modèle professeur" (plus grand).

3.2 Le Mécanisme de Self-Attention

Le cœur de notre modèle repose sur le mécanisme de *Self-Attention*. Contrairement aux réseaux récurrents (LSTM) qui lisent le texte séquentiellement, le Transformer analyse tous les mots de la phrase simultanément. Il calcule un score d'attention entre chaque paire de mots pour comprendre leur relation contextuelle.

Mathématiquement, le mécanisme se définit par l'équation suivante, calculant la relation entre les requêtes (Q), les clés (K) et les valeurs (V) :

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (3.1)$$

Ce mécanisme est particulièrement adapté à l'ABSA : il permet au modèle de prêter "attention" à un adjectif qualificatif (ex : *terrible*) situé très loin du mot définissant l'aspect (ex : *shipping*) dans une même clause.

L'équation d'Attention :

Q , K et V sont des matrices obtenues par multiplication du texte d'entrée avec des poids appris. $\sqrt{d_k}$ est un facteur de mise à l'échelle.

3.3 Couche de Classification et Fonction de Perte

La dernière couche du modèle Transformer génère un vecteur spécifique, appelé token [CLS], qui condense la représentation sémantique globale du segment analysé.

Nous avons ajouté au sommet de ce token une couche linéaire dense (Réseau de neurones *Feed-Forward*), suivie d'une fonction

d'activation *Softmax*, permettant de projeter ce vecteur sur nos trois dimensions cibles : Positif, Neutre ou Négatif.

L'optimisation des poids du modèle lors du *Fine-Tuning* s'effectue par la minimisation de la fonction de perte d'Entropie Croisée (*Cross-Entropy Loss*), calculant l'écart entre la prédiction probabiliste de l'IA et le label réel du jeu de données :

$$\mathcal{L} = - \sum_{c=1}^M y_{o,c} \log(p_{o,c}) \quad (3.2)$$

Où M est le nombre de classes (3), y est l'indicateur binaire (0 ou 1) si la classe c est la bonne classification, et p est la probabilité prédite.

4 Entraînement et Expérimentations

4.1 Hyperparamètres et Configuration d'Apprentissage

Le *Fine-Tuning* d'un modèle Transformer nécessite un réglage minutieux des hyperparamètres, particulièrement lorsque les ressources matérielles sont limitées. Notre objectif était d'entraîner le modèle sur **30 000 avis** issus de notre dataset, répartis selon un ratio standard de 80 % pour l'apprentissage et 20 % pour la validation.

Le tableau suivant récapitule les hyperparamètres retenus pour notre expérimentation :

Hyperparamètre	Valeur
Modèle de base	<code>distilbert-base-uncased</code>
Taille de lot (<i>Batch Size</i>)	4
Longueur maximale de séquence	128 tokens
Taux d'apprentissage (<i>Learning Rate</i>)	2×10^{-5}
Nombre d'époques (<i>Epochs</i>)	2
Décroissance des poids (<i>Weight Decay</i>)	0.01

TABLE 4.1 – Configuration des hyperparamètres du Fine-Tuning.

L'Optimiseur AdamW :

Nous avons utilisé AdamW, une variante de l'optimiseur Adam intégrant une décroissance des poids (*weight decay*). Cela agit comme une régularisation pour limiter le sur-apprentissage.

4.2 Optimisation de la Précision Mixte (FP16)

Pour contourner la limite stricte des 4 Go de VRAM de notre carte graphique locale (Nvidia GTX 1650), nous avons activé la précision mixte (`fp16=True` dans l'API *Hugging Face Trainer*). Plutôt que d'effectuer tous les calculs matriciels en flottants 32-bits (FP32), la carte graphique utilise le format 16-bits pour la majorité des opérations. Cette approche divise par deux l'empreinte mémoire sans dégrader la convergence de l'algorithme ni la qualité finale des prédictions.

5 Résultats et Déploiement

5.1 Protocole de Test : L'Échappement (*Hold-out Test*)

En Intelligence Artificielle, évaluer un modèle sur ses données d'entraînement conduit à un biais majeur : le *Data Leakage* (fuite de données). Le modèle semble performant, mais il a simplement "appris par cœur" (sur-apprentissage).

Pour garantir la rigueur scientifique de notre démarche, l'évaluation finale a été réalisée sur un *Hold-out dataset* : un corpus strict de **1 000 avis jamais présentés au modèle** au cours de son apprentissage (indices 35 000 à 36 000).

5.2 Analyse des Métriques et Matrice de Confusion

Le tableau 5.1 compare les performances obtenues sur le jeu de validation avec celles obtenues sur le jeu de test inédit.

Phase d'Évaluation	Précision (Négatif)	F1-Score (Neutre)	Accuracy Globale
Apprentissage (Jeu de Validation)	91,00 %	66,00 %	92,30 %
Généralisation (Test Inédit)	83,00 %	47,00 %	85,60 %

TABLE 5.1 – Évaluation des performances sémantiques de l'ABSA.

Le modèle atteint une **Exactitude Globale de 85,60 %** sur des données totalement inconnues. Sachant que le taux d'accord humain inter-annotateurs sur l'analyse de sentiment culmine généralement autour de 80-85 %, notre système démontre une excellente capacité de généralisation. D'un point de vue industriel, la **précision de 83 % sur la classe Négative** est un atout majeur : elle garantit que plus de 8 alertes sur 10 déclenchées par l'IA concernent un mécontentement réel, limitant ainsi le bruit pour le service client.

Pourquoi la classe Neutre est-elle difficile ?

Un humain a lui-même du mal à classer un texte neutre. Les avis "Neutres" (3 étoiles) sont souvent un mélange complexe de remarques très positives et très négatives, d'où un F1-Score mécaniquement plus bas.

5.3 Restitution Visuelle et Opérationnelle (Power BI)

Afin de rendre ces prédictions exploitables par les décideurs, la base de données *SQLite* alimentée par notre pipeline Python a été connectée en temps réel à la solution Microsoft Power BI via un connecteur ODBC. Nous avons conçu deux tableaux de bord répondant à deux besoins distincts.

5.3.1 Le Tableau de Bord Stratégique (Vue Décisionnelle)

Cette première page est destinée à la Direction Générale. Elle offre une vision macro-analytique de la santé de la marque. On y retrouve des indicateurs clés de performance (KPIs) tels que le volume d’avis traités et la note moyenne globale. L’apport principal s’illustre via l’histogramme croisant les aspects détectés (Hardware, Logistique, Software) et la distribution des sentiments.




FIGURE 5.1 – Tableau de bord stratégique généré par les prédictions du modèle ABSA.

5.3.2 L’Outil CRM d’Alertes SAV (Vue Opérationnelle)

L’Intelligence Artificielle doit également servir les équipes sur le terrain. La deuxième page agit comme un système CRM d’alerte pour le Service Après-Vente (SAV). Un filtre de sécurité bloque l’affichage si la **Confiance de l’IA est inférieure à 80 %**. Ce mécanisme garantit aux opérateurs de n’avoir à l’écran que les urgences avérées, leur permettant de résoudre le litige quasi instantanément.

Rapport Opérationnel : File d’Attente des Alertes SAV

ID Client	Note Client (sur 5)	Extrait de la Réclamation	Aspect Concerné	Certitude IA
A105L5EX9D0NH8	5,00	it's not a big deal	Price_Value	0,83
A1062JQ0414112	3,00	it looks really bad on the black s4	Hardware_Design	0,92
A10E11MSU070I8	1,00	after charging my phone for 15 minutes the charger began to overheat	Hardware_Design	0,98
A10E11MSU070I8	1,00	had to return this item for refund	Price_Value	1,00
A10E11MSU070I8	1,00	the charge on my phone started to fail	Hardware_Design	0,99
A10H7ADH2K0R	5,00	i wouldnt trust it to save the screen from a 3 foot drop	Hardware_Design	0,46
A10K7QBLN6VLE	5,00	durability	Hardware_Design	0,86
A10K7QBLN6VLE	5,00	one teardrop shaped so fit was not a problem	Hardware_Design	0,43
A10OE3V66RU992	4,00	i tend to think it's a design flaw of the car unit more than the charger itself	Hardware_Design	0,73
A10OE3V66RU992	4,00	it didn't fit properly in my 2013 sonata	Hardware_Design	0,98
A10RMVX6EE90N6	5,00	you want cheap made buy something else	Price_Value	0,91
A10U323FCPX2	5,00	i return my motorola q	Price_Value	0,59
A10U323FCPX2	5,00	i returned it	Price_Value	0,97
A10W13EOAKX0W5	4,00	sticky34	Hardware_Design	0,94
A10YK683DFIJQC	2,00	i am returning this product to amazon	Price_Value	0,96
A10YK683DFIJQC	5,00	i am returning this product to amazon	Price_Value	0,96
A10YVZSMCVWGP	2,00	this does not charge all of the items it fits	Hardware_Design	0,99

FIGURE 5.2 – Outil de priorisation des réclamations pour le Service Après-Vente.

Nous avons conçu deux niveaux de restitution :

- **Une Vue Décisionnelle (Page 1)** destinée à la Direction Générale, présentant les KPI globaux (Note moyenne) et la répartition des plaintes par aspect (Produit, Logistique, etc.).
- **Une Vue Opérationnelle (Page 2)** qui agit comme un véritable CRM d'alerte pour le Service Après-Vente (SAV). Un filtrage strict y est appliqué : seuls les avis **Négatifs** disposant d'un **taux de confiance de l'IA supérieur à 80 %** sont affichés, permettant aux agents de prioriser efficacement la résolution des litiges urgents.

Conclusion Générale et Perspectives

La gestion des retours clients textuels est aujourd'hui un défi majeur pour les entreprises. Ce projet de fin de module nous a permis d'apporter une solution complète, fiable et déployable à ce problème, en concevant un pipeline d'Analyse de Sentiments Orientée Aspect (ABSA) de bout en bout.

Au cours de ce travail, nous avons démontré qu'il était possible de surmonter les limites d'une simple classification globale grâce à l'application de règles linguistiques (NLTK) combinées à la puissance sémantique des réseaux de neurones profonds. Face aux contraintes de nos ressources matérielles (GPU de 4 Go de VRAM), nous avons fait preuve de pragmatisme en ingénierie. L'adoption d'un modèle allégé (DistilBERT), couplée à des optimisations telles que la précision mixte, nous a permis de réaliser un apprentissage local intensif.

Validé scientifiquement par un test d'échappement avec une exactitude de **85,60 %**, le modèle s'est avéré redoutable pour la détection ciblée des insatisfactions. La restitution de ces résultats au sein de l'environnement Power BI prouve la valeur ajoutée d'une telle solution en entreprise, offrant à la fois un tableau de pilotage stratégique et un outil opérationnel de résolution de crise.

Perspectives de Recherche

Bien que performant, ce système ouvre la voie à des axes d'amélioration particulièrement stimulants sur le plan de la recherche scientifique :

1. **Déploiement en temps réel** : La conteneurisation du pipeline (via Docker) et son exposition derrière une API (par exemple, FastAPI) permettraient d'analyser les flux de commentaires en streaming.
2. **Transition vers l'ABSA Multimodal** : Le traitement du texte seul présente des limites, notamment lorsqu'un client joint une image d'un produit endommagé à sa réclamation. S'inscrivant directement dans la continuité des travaux de recherche de notre encadrant et de l'USMBA, l'évolution naturelle de ce projet consisterait à concevoir une architecture multimodale. Celle-ci fusionnerait les représentations textuelles des Transformers avec les vecteurs de caractéristiques visuelles issus de réseaux convolutifs (CNN), via un mécanisme d'attention croisée, pour offrir une analyse sémantique

d'une précision inégalée.

Ce projet a constitué une formidable opportunité de conjuguer la rigueur académique aux exigences de la pratique industrielle, consolidant nos compétences en ingénierie de données, en intelligence artificielle appliquée et en *Business Intelligence*.